

Corporate Bond Rating Using Various Multiclass Support Vector Machines*

Hyunchul Ahn**, Kyoung-jae Kim***

Corporate credit rating is a very important factor in the market for corporate debt. Information concerning corporate operations is often disseminated to market participants through the changes in credit ratings that are published by professional rating agencies, such as Standard and Poor's (S&P) and Moody's Investor Service. Since these agencies generally require a large fee for the service, and the periodically provided ratings sometimes do not reflect the default risk of the company at the time, it may be advantageous for bond-market participants to be able to classify credit ratings before the agencies actually publish them. As a result, it is very important for companies (especially, financial companies) to develop a proper model of credit rating.

From a technical perspective, the credit rating constitutes a typical, multiclass, classification problem because rating agencies generally have ten or more categories of ratings. For example, S&P's ratings range from AAA for the highest-quality bonds to D for the lowest-quality bonds. The professional rating agencies emphasize the importance of analysts' subjective judgments in the determination of credit ratings. However, in practice, a mathematical model that uses the financial variables of companies plays an important role in determining credit ratings, since it is convenient to apply and cost efficient. . These financial variables include the ratios that represent a company's leverage status, liquidity status, and profitability status.

Several statistical and artificial intelligence (AI) techniques have been applied as tools for predicting credit ratings. Among them, artificial neural networks are most prevalent in the area of finance because of their broad applicability to many business problems and their preeminent ability to adapt. However, artificial neural networks also have many defects, including the difficulty in determining the values of the control parameters and the number of processing elements in the layer as well as the risk of over-fitting. Of late, because of their robustness and high accuracy, support vector machines (SVMs) have become popular as a solution for problems with generating accurate prediction. An SVM's solution may be globally optimal because SVMs

* This work was supported by the research program of Dongguk University.

** Full-time Lecturer, School of Business IT, Kookmin University

*** Corresponding author, Associate Professor, Department of Management Information System, Dongguk University

seek to minimize structural risk. On the other hand, artificial neural network models may tend to find locally optimal solutions because they seek to minimize empirical risk. In addition, no parameters need to be tuned in SVMs, barring the upper bound for non-separable cases in linear SVMs. Since SVMs were originally devised for binary classification, however they are not intrinsically geared for multiclass classifications as in credit ratings. Thus, researchers have tried to extend the original SVM to multiclass classification. Hitherto, a variety of techniques to extend standard SVMs to multiclass SVMs (MSVMs) has been proposed in the literature. Only a few types of MSVM are, however, tested using prior studies that apply MSVMs to credit ratings studies.

In this study, we examined six different techniques of MSVMs: (1) One-Against-One, (2) One-Against-All, (3) DAGSVM, (4) ECOC, (5) Method of Weston and Watkins, and (6) Method of Crammer and Singer. In addition, we examined the prediction accuracy of some modified version of conventional MSVM techniques. To find the most appropriate technique of MSVMs for corporate bond rating, we applied all the techniques of MSVMs to a real-world case of credit rating in Korea. The best application is in corporate bond rating, which is the most frequently studied area of credit rating for specific debt issues or other financial obligations. For our study the research data were collected from National Information and Credit Evaluation, Inc., a major bond-rating company in Korea. The data set is comprised of the bond-ratings for the year 2002 and various financial variables for 1,295 companies from the manufacturing industry in Korea.

We compared the results of these techniques with one another, and with those of traditional methods for credit ratings, such as multiple discriminant analysis (MDA), multinomial logistic regression (MLOGIT), and artificial neural networks (ANNs). As a result, we found that DAGSVM with an ordered list was the best approach for the prediction of bond rating. In addition, we found that the modified version of ECOC approach can yield higher prediction accuracy for the cases showing clear patterns.

Keywords : Multiclass Support Vector Machines, Directed Acyclic Graph, Error-Correcting Output Code, Bond Rating

다양한 다분류 SVM을 적용한 기업채권평가

안 현 철, 김 경 재

I. 서 론

기업 신용등급에 대한 적절한 평가는 금융시장에서 매우 중요한 요소 중 하나다. 이러한 신용등급의 평가는 스탠다드 앤 푸어스(Standard and Poor's), 무디스(Moody's), 한국신용평가, 한국기업평가 등 국내외 신용평가회사에 의해 이루어

어지는데, 기업 경영과 관련된 정보가 종종 '신용 등급 변화'의 형태로 시장 참여자들에게 전파된다는 점을 고려할 때 그 파급효과가 매우 크다고 할 수 있다. 일반적으로 국내외 신용평가회사들이 신용평가 서비스 제공에 요구하는 수수료는 상당히 높은 편이다. 뿐만 아니라, 그들이 공시하는 신용등급은 일정한 시간간격에 따라 갱

신되므로, 가끔 특정 시점의 회사가 갖고 있는 부도위험을 제대로 반영하지 못할 때가 있다. 이러한 점으로 미루어 볼 때, 채권 시장 참여자들이 외부 신용평가회사에서 기업 신용등급 결과를 공표하기 전에, 자체적으로 투자대상에 대한 신용등급을 정확히 예측하고 활용하는 것은 굉장히 유익할 수 있다. 그 결과 오늘날 많은 기업들(특히 금융회사들)이 기업 신용등급 평가를 위한 적절한 예측 모형을 개발하여 활용하는 것이 점차 중요해지고 있다[Cao *et al.*, 2006].

일반적으로 신용평가 회사들은 10개 혹은 그 이상으로 구성된 등급체계에 의해 기업의 신용등급을 부여한다. 예를 들어, S&P의 경우 장기채에 대해서는 최고 AAA등급부터 최하 D등급까지 총 10등급으로 구분된 등급을 기본적으로 사용하며, 단기채에 대해서는 A-1, A-2, A-3, B, C, D 등 6등급 체계를 사용한다¹⁾. 따라서, 기술적인 관점에서 볼 때, 신용등급 예측은 전형적인 다분류(multiclass classification) 문제에 속한다. S&P, Moody's와 같은 전문적인 신용평가업체들의 경우, 신용등급을 판정하는데 있어서 분석가(평가담당자)의 주관적인 의견을 반영하여 보다 양질의 등급을 산출할 수 있도록 노력한다. 그러나 이는 상당한 분석 시간과 비용을 유발시킬 수 있으므로, 보통은 적용이 간편하고 시간/비용을 그다지 필요로 하지 않는 재무변수 기반의 수리모형(mathematical model)이 현업에서 중요한 역할을 수행한다. 이러한 모형의 입력변수들로는 일반적으로 기업의 레버리지 상태, 유동성 상태, 그리고 수익성 상태 등을 나타내는 각종 재무비율 변수들이 활용된다[Huang *et al.*, 2004; Cao *et al.*, 2006].

전술한 신용등급 예측모형을 개발하는데 있어, 다양한 통계적 기법들과 인공지능 기법들이 학계 또는 현업에서 제시되고, 활용되어 왔다[Fisher,

1959; Pinches and Mingo, 1973; Dutta and Shekhar, 1988; Kim, 1993; Altman *et al.*, 1994; Shin and Han, 1999 등 참고]. 그 중에서도 특히 인공신경망(ANN, artificial neural networks) 기법은 우수한 예측능력으로 인해, 신용등급 예측과 같은 다분류(多分類, multiclass classification) 재무문제 해결은 물론, 부도예측 등과 같은 이분류(二分類, binary classification) 재무문제의 해결에도 최근까지 활발하게 적용되어 왔다. 그러나 한편으로는 많은 연구자들이 인공신경망을 적용할 경우 발생할 수 있는 여러 문제점들을 지적하였다. 예를 들어, 자유도(degree of freedom) 문제로 인해 학습에 많은 학습데이터가 요구된다는 점, 학습 시 과적합문제(overfitting problem)가 발생할 수 있다는 점, 각종 설계에 적용되는 파라미터값을 설정하는데 있어서 설계자의 직관(heuristic)에 의존해야 한다는 점, 그리고 모형이 구축된 이후에도 과도한 복잡성으로 인해 해석이 사실상 불가능하여 이른바 암상자 모형(black box model)으로 불린다는 점 등을 인공신경망의 치명적인 문제점으로 들 수 있다. 이러한 문제를 해결할 수 있는 대안을 찾고자 하는 시도가 지금까지 학계에서 많이 이루어졌는데, 최근 새로운 인공지능 기반의 분류기법 중 하나인 SVM(support vector machine)이 그 대안으로 부상하고 있다. 기존 인공신경망 모형은 경험적 위험 최소화 원칙에 따라 국소 최적화된 해에 빠질 수 있는 위험이 높지만, SVM은 구조적 위험 최소화 원칙에 의해 학습을 수행하므로 전역 최적해를 탐색할 수 있다. 또한 인공신경망과 달리 최적화 해야 할 파라미터의 수도 훨씬 적고, 이른바 서포트 벡터(support vector)라 불리는 경계면 주변의 샘플만 학습에 사용하기 때문에, 학습에 필요한 데이터수가 많이 요구되지 않는다는 장점도 있다. 뿐만 아니라, 예측성과의 측면에서도 인공신경망과 비교해 볼 때, 대부분 뒤쳐지지 않으며, 오히려 많은 기존 연구에서 SVM이 더 우수한 성과를 보인다는 사실이 소개

1) S&P 웹 사이트 참고: <http://www2.standardandpoors.com/portal/site/sp/en/us/page.article/2,1,3,0,1204844424546.html>.

되고 있다[Ahn *et al.*, 2006]. 그러나, SVM은 처음부터 이분류 문제를 해결하기 위한 방법으로 고안된 기법이기에 때문에, 신용등급 평가와 같은 다분류 문제의 해결에는 직접적으로 적용될 수 없다 [Vapnik, 1995]. 따라서, 지금까지 많은 컴퓨터 과학 분야의 연구자들이 본래 SVM을 다분류 기법으로 확장/변형시키기 위한 다양한 접근법을 연구해 왔다. 그 결과, 표준 SVM을 다분류 SVM 모형으로 확장하는 기법으로 지금까지 대략 6가지 정도의 대표적인 기법들이 컴퓨터 공학 분야의 기존 문헌들에서 소개되고 있다[Lorena and de Carvalho, 2008]. 그러나, 다분류 SVM을 기업 신용등급 예측에 적용한 기존 연구들은 다분류 SVM 기법이 이렇게 다양하게 존재하고 있음에도 불구하고, 대부분 1~2가지, 많아야 3가지 정도의 기법에 대해서만 검증을 시도하는 것이 보통이었다[Huang *et al.*, 2004; Ahn *et al.*, 2006; Cao *et al.*, 2006; Chen and Shih, 2006; Lee, 2007].

이러한 취지에서 본 연구는 지금까지 개발된 모든 여섯가지 종류의 다분류 SVM 기법들을 모두 국내 채권등급 예측 모형 개발에 적용해 보고, 채권등급 예측 분야에 있어 가장 효과적인 다분류 SVM 기법을 탐색해 보고자 한다. 아울러, 이 결과들을 전통적으로 채권등급 평가에 적용되어 온 판별분석(multiple discriminant analysis, MDA), 다항 로지스틱 회귀분석(multinomial logistic regression, MLOGIT), 리고 인공신경망(artificial neural network, ANN) 기법과도 비교해 봄으로써, 과연 기존 연구자들의 주장처럼 다분류 SVM이 정확도와 안정성을 동시에 보장하는 효과적인 채권등급 예측 기법이 될 수 있는지 확인해 보고자 한다. 아울러, 본 연구에서는 컴퓨터 공학 분야에서 제시된 6가지 다분류 SVM 기법 중, DAGSVM 기법과 ECOC 기법에 대해서는 다소 변형된 기법을 제시하고, 이 기법들의 성과도 고찰해 볼 것이다.

본 연구의 구성은 다음과 같다. 우선 제 II장에

서는 본 연구와 관련한 각종 이론적 배경에 대해 살펴보고, 제 III장에서는 본 연구의 목적을 달성하기 위한 실험데이터와 실험설계를 소개한다. 이어 제 IV장에서는 실험결과를 제시하고, 이를 분석할 것이며, 끝으로 마지막 제 V장에서는 결론과 함께 본 연구의 한계점을 제시하고자 한다.

II. 이론적 배경

본 장에서는 우선 본 연구의 적용분야인 채권 등급평가 모형과 관련해 제시된 기존 연구들을 고찰해 보고, 이어 본 연구의 핵심이라고 할 수 있는 다분류 SVM 모형과 이를 구현하는 6가지 기법들에 대해 소개한다. 이어 다분류 SVM 모형을 적용해 채권등급평가를 하고자 했던 기존 연구들을 간략히 살펴보면, 왜 본 연구가 필요한지에 대한 연구의 당위성을 제시하고자 한다.

2.1 채권등급평가모형

계량적인 접근을 통해 채권등급을 예측하려는 시도는 OLS(ordinary least squares)를 활용하여 채권의 위험에 대한 보상(risk premium)의 분산을 설명하려고 했던 Fisher[1959]의 연구가 시초라고 할 수 있다. 이어 다분류 문제를 해결할 수 있는 통계기법인 다중판별분석이나 다항 로지스틱 회귀분석을 활용한 연구들이 시도되었는데, 대표적인 연구로는 Pinches and Mango [1973; 1975]나 Ederington[1985] 등을 들 수 있다. 현재도 통계기법은 채권등급평가를 위한 기법으로 많이 사용되고 있으며, 연구논문에서도 종종 발견할 수 있다. 하지만, 연구논문에서는 주로 인공지능기법의 성과 비교를 위한 용도로 주로 활용되는데, 그 이유는 인공지능기법이 통계적 기법에 비해 월등한 예측성적을 보이기 때문이다 [Ahn *et al.*, 2006].

인공지능기법은 1980년대 후반부터 재무예측 분야에 본격적으로 활용되기 시작했다. 이 중 가장

활발하게 적용된 기법은 인공신경망인데, 인공신경망을 채권등급예측에 적용한 연구로는 Dutta and Shekhar[1988]와 Kim[1993], Kwon *et al.*[1997], Chaveesuk *et al.*[1999] 등을 들 수 있다. 이러한 연구들은 앞서 소개한 통계적 기법들과 BP(back propagation), RBF(radial basis function), LVQ(learning vector quantization) 등 다양한 종류의 인공신경망 기법들의 예측성과를 주로 비교하였는데, 모든 연구에서 인공신경망 모형의 채권등급 예측결과가 더 우수한 것으로 보고되었다. 인공신경망 기법 이외에도 다른 인공지능기법들이 채권등급예측 모형에 종종 적용되었는데, Shin and Han[1999]는 유전자 알고리즘(genetic algorithm, GA)에 의해 최적화된 사례기반추론 기법을 제안하였고, Shin and Han[2001]은 의사결정나무 기법과 사례기반추론이 결합된 새로운 하이브리드(hybrid) 기법을 제안하였다. 그러나 몇몇 연구들을 제외하고는, 지금까지 인공신경망 기법이 채권등급예측 모형 구축에 가장 널리 적용되었다고 할 수 있다.

이처럼 많은 연구논문들이 인공신경망의 높은 예측정확성을 제시해 왔지만, 모형이 산출하는 결과에 대한 설명력이 부족하여 예측결과의 원인을 설명하기 어렵다는 점과 소량의 자료를 대상으로 실험을 하였을 때 모형의 학습이 어렵다는 점, 모형을 구축함에 있어 과도적합의 문제와 신경망 구조의 설계를 위해 많은 시간과 노력이 필요하다는 점 등 인공신경망의 한계점도 지적되었다[Altman *et al.*, 1994; Jo and Han, 1996]. 특히, 학습에 많은 데이터를 필요로 한다는 한계점은 채권등급평가와 같은 다분류 문제의 경우에 매우 치명적인 약점이 될 수 있다. 왜냐하면 각 등급별로 데이터를 구분해야 하기 때문에, 간혹 특정 등급에 속한 데이터가 매우 희소한 경우가 발생할 수 있기 때문이다. 이러한 문제로 인해, 최근에는 적은 데이터로도 높은 예측 정확도를 보일 수 있는 인공지능기법인 SVM이 인공신경망을 대체할 새로운 대안으로 급부상하고 있

다. 그 결과, 채권등급평가에도 SVM을 적용한 논문들이 소개되고 있는데, 이들 논문들에 대한 분석은 다음 제 4절에서 자세히 논의하고자 한다.

2.2 표준 SVM

본 절에서는 이분류를 위한 일반적인 SVM의 원리에 대해 설명한다. SVM은 모형학습용 데이터들을 두 집단으로 분류할 때, 기준이 되는 분리 경계면(hyperplane)을 학습 알고리즘을 통해 탐색하는 형태로 작동된다. 구체적으로, SVM은 학습용 입력벡터 x 를 고차원의 특징공간으로 사상시킨 다음, 두 집단 사이의 폭(margin)을 최대화시키는 분리 경계면을 찾는 것을 목적으로 한다. 이러한 최대폭 분리 경계면(maximum margin hyperplane)은 두 집단 사이의 거리를 최대로 분리시킨다. 이 때 최대마진 분리 경계면에 가장 근접한 데이터들로, 모형의 학습에 반영되는 모형학습용 데이터를 서포트 벡터(support vector)라고 부른다[Ahn *et al.*, 2006].

상기 과정을 간단한 수식으로 예를 들어 살펴보면 다음과 같다. 우선 선형분리문제에서, 독립변수가 3개인 경우 분리 경계면은 다음의 식 (1)과 같이 표현할 수 있다.

$$y = w_0 + w_1x_1 + w_2x_2 + w_3x_3 \quad (1)$$

여기서 y 는 출력값이고, x_i 는 변수값, 그리고 4개의 w_i 는 학습 알고리즘에 의해 학습된 가중치이다. 상기 식에서 가중치 w_i 는 분리 경계면을 결정하는 파라미터이다. 이 때 최대마진 분리 경계면은 서포트 벡터를 사용해서 다음의 식 (2)와 같이 나타낼 수 있다.

$$y = b + \sum \alpha_i y_i x(i) \cdot x \quad (2)$$

여기서, y_i 는 모형학습용 데이터 $x(i)$ 의 분류

값이고, \cdot 는 내적(dot product)이다. 한편, 벡터 x 는 모형검증용 데이터를 나타내고, 벡터 $x(i)$ 는 서포트 벡터를 나타낸다. 이 식에서, b 와 α_i 는 분리 경계면을 결정하는 파라미터이다. 이때, 서포트 벡터를 찾아내고, 파라미터 b 와 α_i 를 결정하는 것은 선형적으로 제약된 이차계획문제(linearly constrained quadratic programming)를 푸는 것과 같다[Chang and Lin, 2001].

전술했듯이, SVM은 저차원의 입력변수를 고차원의 특징 공간으로 이동시킴으로써 비선형 분류문제를 선형 분류기로 분류하도록 설계되어 있다. 이 때, 비선형 분류문제에서 사용될 식 (2)의 고차원 형태는 다음 식 (3)과 같이 나타낼 수 있다.

$$y = b + \sum \alpha_i y_i K(x(i), x) \quad (3)$$

식 (3)에서 함수 $K(x(i), x)$ 는 커널함수(kernel function)라고 정의된다. 커널함수는 원래 데이터를 고차원 공간으로 사상시킴으로써 특징공간 내에 선형으로 분리가능한 입력 데이터셋을 만든다. 이 때 사용될 수 있는 커널함수는 여러 가지가 있으며 어떤 커널함수를 선택하는 것이 바람직한가는 문제에 따라 상이하고, 이는 SVM을 적용하는 데 있어서 가장 중요한 요소 중의 하나이다. 일반적으로 많이 사용되는 커널함수로는 선형함수(linear function)와 다항식 함수(polyynomial function), 그리고 가우시안 RBF 함수(Gaussian radial basis function)를 들 수 있으며, 각 함수식은 아래와 같다.

$$\text{선형 함수: } K(x, y) = xy \quad (4)$$

$$\text{다항식 함수: } K(x, y) = (xy + 1)^d \quad (5)$$

가우시안 RBF:

$$K(x, y) = \exp\left(-\frac{1}{\sigma^2}(x-y)^2\right) \quad (6)$$

여기서 d 는 다항식 함수의 차수이고, σ^2 은 가우시안 RBF 함수의 대역폭이다.

분리가능한 문제에 있어서 상기 식의 계수 α_i 의 하한은 0이다. 분리가 불가능한 문제에서 SVM은 계수 α_i 의 하한 이외에 상한 C 를 추가함으로써 일반화된 결과를 얻을 수 있다[Kim, 2003; Ahn *et al.*, 2006].

2.3 다분류 SVM: 6가지 구현기법

앞서 제 1절에서 소개한 바와 같이, 최근 SVM을 채권등급평가에 적용하는 연구들이 속속 등장하고 있다. 그러나, 본래 SVM은 단일 분류기(one classifier)에 의해 이루어지는 이분류 기법으로 설계되었기 때문에, 채권등급평가와 같은 다분류 문제해결에 적용되기 위해서는 변형된 SVM 모형을 적용하여야 한다[Vapnik, 1995]. 이처럼 세 개 이상의 등급으로 구분된 종속변수를 예측하는 SVM 기반의 모형을 다분류 SVM 모형이라고 부른다. 다분류 SVM을 구현하기 위해서는 전통적인 SVM 기법을 변형 혹은 확장시켜야 하는데, 어떤 형태로 변형 또는 확장시킬 것인가에 대해 최근 5년여 시간 동안 많은 연구가 이루어졌고, 또 다양한 기법들이 제안되었다. 이렇게 기존의 SVM을 다분류 SVM으로 확장시키는 기법들은 크게 두 부류로 구분되어진다. 첫 번째 부류는 다분류 문제를 여러 개의 이분류 문제로 쪼개서, 여러 개의 이분류 SVM 분류기를 구축, 결합함으로서 다분류 SVM을 구현하는 기법들이다. 두 번째 부류는 모든 데이터를 한꺼번에 고려해서, 하나의 단일화된 최적화 문제를 해결함으로서 다분류 SVM을 구현하는 기법들이다. 결국 전자는 본래의 SVM을 모형상으로 변화시키지 않고, 복수 개의 분류기를 사후적으로 결합하여 예측을 수행하는 접근법인 반면, 후자는 본래의 SVM 모형 자체를 다분류 문제에 적합하도록

록 근본적으로 재설계 한다는 측면에서 그 차이가 있다고 하겠다[Lorena and de Carvalho, 2008; Wu *et al.*, 2008].

다음의 <표 1>은 다분류 SVM을 구현하는 가장 대표적인 6가지 기법들과 그 기법들이 상기 두 부류 중 어디에 해당되는지를 개괄적으로 제시하고 있다. 지금부터 각 기법들에 대해 좀 더 상세히 살펴보도록 한다.

2.3.1 다중의 이분류 분류기들을 결합:

(1) One-Against-All

이 기법은 논문에 따라 ‘One-versus-All’이나 ‘One-Against-Rest,’ 또는 ‘One-versus-Rest’ 등으로 불리기도 한다. 개념적으로 이 방법은 가장 단순한 다분류 기법이다. 이 방법은 k 개의 등급으로 구분된 다분류 문제에 대해, 등급1(+1) 對 나머지 등급들(-1), 등급2(+1) 對 나머지 등급들(-1), 등급3(+1) 對 나머지 등급들(-1)··· 등급 k (+1) 對 나머지 등급들(-1)과 같은 형태로 총 k 개의 이분류 SVM 분류기를 구축하는 방식이다[Kreßel, 1999].

One-Against-All 기법에서 최종 판단을 내리는 결합함수는 k 개의 이분류 함수들 중에서 분류면(hyperplane)에서 가장 멀리 떨어진 값을 산출하는 등급을 최종 등급으로 산출하도록 설계된다. 즉, 각 등급에 대해 +1을 산출할 가능성(확

률)이 가장 높은 등급을 최종 등급으로 판정하는 것이다. 이 기법은 비교적 적은 수의 분류기만 구축하면 되기 때문에 효율성이 높다는 장점이 있다[Statnikov *et al.*, 2005].

2.3.2 다중의 이분류 분류기들을 결합:

(2) One-Against-One

이 기법 역시 논문에 따라 표기가 조금씩 틀려 지는데, ‘All-Against-All,’ ‘One-versus-One,’ 그리고 가끔씩 ‘Pairwise Classification’으로 표기되기도 한다. 이 기법에서는 모형이 각 등급 쌍(pair)에 대한 모든 경우에 대해 이분류 SVM 분류기를 구축한다. 그래서, 총 ${}_kC_2 = k(k-1)/2$ 쌍에 해당하는 이분류 SVM 분류기를 구축하게 된다. 예를 들어, A, B, C, D의 4개 등급으로 구분된 문제를 푼다고 할 때, 앞의 One-Against-All의 경우, A 對 (B, C, D), B 對 (A, C, D), C 對 (A, B, D), D 對 (A, B, C)의 총 4가지 분류기만 구축하게 되지만, One-Against-One에서는 A 對 B, A 對 C, A 對 D, B 對 C, B 對 D, C 對 D 등 총 6가지 분류기를 구축하게 된다. 이렇게 이분류 SVM 분류기들이 구축되고 나면, 최종 등급을 판정하는 함수는 각 분류기의 투표 결과 가장 많은 표를 획득하는 등급을 선택하게 된다. 즉, 이른바 Max Wins(간혹 ‘vote count’ 또는 ‘winner-takes-all’이라고도 호칭됨) 전략을 적

<표 1> 다분류 SVM의 6가지 구현기법

분 류	기 법	구축해야 할 분류기의 수*
여러 개의 이분류 SVM 분류기를 결합	(1) One-Against-All	k
	(2) One-Against-One	${}_kC_2 = k(k-1)/2$
	(3) DAGSVM	${}_kC_2 = k(k-1)/2$
	(4) ECOC	$\log_2 k \sim 2^{k-1} - 1$
모든 데이터를 한꺼번에 고려	(5) Weston and Watkins의 방법	1
	(6) Crammer and Singer의 방법	1

주) * 해결해야 할 다분류 문제가 k 개의 등급으로 구성되어 있을 경우 요구되는 분류기의 개수.

용해, 최종 등급을 판정하는 것이다. 만일 투표 결과 동점이 발생할 경우에는 두 분류기 중에서 분류면에서 더 멀리 떨어진 값을 산출한 등급을 최종 등급으로 판정하게 된다[Friedman, 1996; Kreßel, 1999].

2.3.3 다중의 이분류 분류기들을 결합:

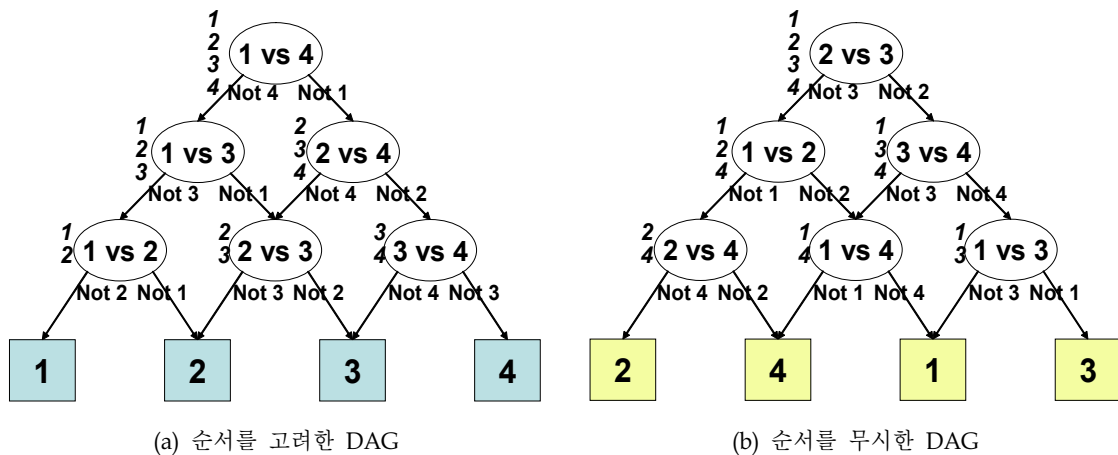
(3) DAGSVM

다중의 이분류 분류기들을 결합하는 세 번째 기법은 방향성 비순환 그래프(directed acyclic graph, DAG)에 기반한 SVM 기법이다. 이 기법의 경우, 학습 단계는 One-Against-One과 동일하다. 즉, 여기에서도 k 개의 등급을 가진 다분류 문제의 경우, kC_2 개의 이분류 분류기를 구축하게 된다. 단, 이 결과를 갖고 해석하는데 있어서, 투표를 사용하는 대신 DAG 그래프에 기반해 해석을 하게 된다. DAG 그래프는 <그림 1>에서 볼 수 있는 것과 같이 각 노드마다 2개의 가지를 갖는 형태로 구성되며, 각 노드는 각 등급별 쌍에 대한 이분류 SVM 분류기를 나타내는데, 예를 들어 p 등급과 q 등급을 구분짓는 이분류 SVM 분류기의 경우, (p, q) 의 형태로 표기할 수 있다. (p, q) 로 표기되는 각 루트 노드(root node)나 자식

노드(child node)의 경우에는 2개의 가지를 갖게 되는데, 이 때 왼쪽 가지는 “not p ”의 상황에 대응되고, 오른쪽 가지는 “not q ”의 상황에 대응된다. 그렇게 해서 아래로 내려오다보면, 위상으로 볼 때 가장 하단에 위치한 k 개의 종단 노드(leaf node)에 의해 k 개의 등급을 판단할 수 있게 된다.

이러한 DAGSVM 기법의 장점은 이론적인 일반화가 이루어져 있어, 안정적이라는 점이다. 아직 One-Against-All이나 One-Against-One 기법에 대해서는 이론적으로 기법의 우수성에 대한 증명이 시도되거나 이루어지지 못했지만, 이 기법은 제안자에 의해 이론적으로 성능이 검증되었다. 또한 One-Against-One과 비교해 볼 때, 학습에 드는 시간은 똑같이 소요되지만, 최종 판정(testing)에 걸리는 시간은 훨씬 단축된다는 장점도 가지고 있다[Platt et al., 2000].

본래 DAGSVM 기법은 순서가 있는(ordinal) 다분류 문제를 고려하고 설계된 기법이 아니라, 순서가 없는(nominal) 다분류 문제를 대상으로 설계된 기법이므로, DAG를 구성하는 방법에 대해서는 특별히 제안된 바 없다. 그러나 순서가 있는 다분류 문제의 경우, 인접한 등급간 분류보다는 멀리 떨어져 있는 등급간 분류가 훨씬 패턴



<그림 1> DAGSVM의 2가지 종류

이 더 뚜렷하게 나타날 것이므로, 판정 시 패턴이 뚜렷한 분류부터 먼저 수행하고, 나중에 패턴이 다소 불투명한 분류를 수행하는 것이 예측성과를 조금이라도 높이는데 기여할 수가 있다. 이러한 생각을 반영하여, 본 연구에서는 DAG 리스트를 <그림 1>에 제시된 바와 같이, 2가지 종류로 나누어 실험을 해보고자 한다. 하나는 좌측에 있는 것처럼 순서를 고려하여 가장 패턴이 뚜렷한 등급간 구분부터 먼저 수행하도록 설계된 순서를 고려한 DAG이고, 다른 하나는 순서에 관계없이 설계된 DAG가 되겠다. 그래서, 두 DAG를 적용했을 때 어떤 결과가 나오는지 살펴보고, 등급의 순서 정보가 다분류 문제 해결에 어떤 영향을 미치는지 살펴보고자 한다.

2.3.4 다중의 이분류 분류기들을 결합:

(4) ECOC

간단히 ECOC라 불리는 오류 정정 산출 부호 기법(Error-Correcting Output Coding, ECOC)은 디지털 통신 이론에서 차용된 기법으로서, 개별 이분류 SVM 분류기에서 나온 결과를 혼합하여 최종 등급을 산출하는 기법이다[Dietterich and Bakiri, 1995]. 이 기법은 학습을 통해 소위 부호 행렬(code-matrix)을 구축하게 되는데, 이 부호 행렬의 행 i 는 등급 i 의 부호 벡터(code-vector)를 의미하고, 열 j 는 해당 분류기가 어떤 결과를 산출했는지의 산출값을 나타내게 된다. 그래서, 최종 등급을 산출하고자 할 때에는 각 행의 부호 벡터가 본래 그 등급에서 나와야 하는 값들의 집합인 오류 정정 부호(error-correcting code)와 비교하여, 가장 차이가 적은 등급을 최종 등급으로 판정하게 된다. 이 때, 가장 차이가 적은 등급을 계산할 때에는 통신 분야에서 많이 사용되는 해밍 거리(Hamming distance)를 이용해, 그 값이 가장 작은 등급을 선택하게 된다 [Klautau *et al.*, 2003; Übeyli, 2008].

그런데, 해밍 거리는 동일한 길이를 가진 두

개의 문자열에서 위치는 같지만 서로 내용이 다른 문자의 개수로 정의된다. 때문에, ECOC를 적용하다 보면, 두 개 혹은 그 이상의 등급이 서로 동일한 최소 해밍 거리를 갖게 되는 경우가 상당히 많다. 이런 경우, 최종 등급을 산출하기 위한 방법으로 2가지를 생각해 볼 수 있는데, 하나는 각 분류기의 소속 확률(membership probability)의 합이 가장 큰 등급을 최종 등급으로 산출하는 방법이고, 다른 하나는 이러한 모호한 사례에 대해서는 “모르겠음(I don't know)”으로 판정하고, 판단을 보류하는 방법이다. 일반적인 ECOC에서는 전자의 방법을 사용하지만, 확실한 경우에 대해서만 채권등급 판정을 해도 유익한 상황이라면 후자의 방법도 의미가 있을 수 있다. 이에 본 연구에서는 이 두 가지 기법을 모두 적용해 보고, 그 결과를 살펴보고자 한다.

ECOC 기법에 대한 독자들의 이해를 돕기 위해, 예를 들어보면 다음과 같다. 만약 4개의 등급이 있는 다분류 문제에 ECOC 기법을 적용한다면, 다음의 <그림 2>의 (a)와 같이 7개의 분류기로 구성된 부호 행렬을 산출할 수 있다. 이 때, <그림 2>의 (b)는 오류 정정 부호들로만 구성된 행렬을 나타내고 있다. 따라서, (a)와 (b)를 토대로 하여, 각 등급별 해밍 거리를 계산해보면 등급 1의 경우는 3, 등급 2의 경우는 1, 등급 3의 경우는 2, 그리고 등급 4의 경우에는 4가 됨을 알 수 있다. 따라서, ECOC에서 이 샘플에 대한 최종 등급은 해밍 거리의 값이 가장 작은 ‘등급 2’로 판정하게 된다.

앞서 살펴본 예에서는 7개의 분류기를 사용했지만, 일반적으로 k 개의 등급이 존재하는 다분류 문제에서 ECOC를 적용한다면, 최소 $\log_2 k$ 개부터 최대 $2^{k-1} - 1$ 개의 이분류 분류기까지 사용할 수 있다. 최소 $\log_2 k$ 개만 있어도 분류가 가능한 이유는 이분류 분류기가 +1 또는 -1로 분류하므로, 하나의 분류기에서 2가지 상태가 표현 가능하기 때문이다. 즉, $2^{\log_2 k} = k$ 의 관계가 성립하

분류기: 등급 $p(+1)$ 대 등급 $q(-1)$

	분류기1 : 1 대 (2,3,4)	분류기2 : 2 대 (1,3,4)	분류기3 : 3 대 (1,2,4)	분류기4 : 4 대 (1,2,3)	분류기5 : (1,2) 대 (3,4)	분류기6 : (1,3) 대 (2,4)	분류기7 : (1,4) 대 (2,3)
등급1	+1	+1	-1	+1	+1	-1	+1
등급2	-1	+1	+1	-1	+1	-1	-1
등급3	-1	+1	+1	-1	+1	+1	-1
등급4	-1	-1	+1	+1	+1	+1	-1

(a) ECOC 부호 행렬의 예

분류기: 등급 $p(+1)$ 대 등급 $q(-1)$

	분류기1 : 1 대 (2,3,4)	분류기2 : 2 대 (1,3,4)	분류기3 : 3 대 (1,2,4)	분류기4 : 4 대 (1,2,3)	분류기5 : (1,2) 대 (3,4)	분류기6 : (1,3) 대 (2,4)	분류기7 : (1,4) 대 (2,3)
등급1	+1	-1	-1	-1	+1	+1	+1
등급2	-1	+1	-1	-1	+1	-1	-1
등급3	-1	-1	+1	-1	-1	+1	-1
등급4	-1	-1	-1	+1	-1	-1	+1

(b) 4등급 다분류 문제에 대한 ECOC의 오류정정부호

<그림 2> ECOC의 부호 행렬과 오류정정부호

로, $\log_2 k$ 개의 이분류 분류기만 있으면, k 개의 다분류 문제를 해결할 수 있다. 그러나, 정보의 양이 많으면 그 만큼 양질의 분류가 가능하기 때문에, 더 많은 분류기를 사용할수록 일반적으로 예측성과는 더 높아진다[Wu *et al.*, 2008]. 그러나 분류기가 많아지면, 학습과 등급 판정에 소요되는 시간 역시 증가될 수 있다는 점 역시 고려해야 한다. 본 논문에서는 채권등급평가 모형 구축 시, ECOC의 정보량을 극대화 하기 위해 $2^{k-1}-1$ 개의 분류기를 사용하기로 한다[Wu *et al.*, 2008].

2.3.5 모든 데이터를 한꺼번에 고려하는 새로운 모형 구축: (5) Weston and Watkins 방법

이 기법은 이분류 SVM 분류 문제를 자연스럽게

게 다분류 문제로 확장하는 접근방법을 취한다. 그래서, k 개의 등급으로 구성된 다분류 문제(독립변수의 수는 l , 학습할 샘플의 수는 n)의 경우, 이는 $(k-1)n$ 크기의 단일 이차계획 문제(single quadratic optimization problem)를 해결하는 것이 되는데, $k=2$ 인 경우 이 다분류 문제는 이분류 SVM 구축 문제와 동일해진다[Weston and Watkins, 1999]. 본 방법에 대한 자세한 수리적 접근 원리는 Weston and Watkins[1999]를 참고하기 바란다. 본 모형을 실제로 푸는 과정에 있어서, 이러한 이차계획 문제에서 목적식에 약간의 변형(상수항을 추가)을 가하면, 소위 bounded-formulation이 가능해 지는데, 이 경우 보다 빠른 속도로 최적화 문제를 해결할 수 있게 된다[Hsu and Lin, 2002a; Hsu and Lin, 2002b].

2.3.6 모든 데이터를 한꺼번에 고려하는 새로운 모형 구축: (6) Crammer and Singer 방법

이 기법은 앞서 소개한 Weston and Watkins 방법과 매우 유사하며, 앞의 기법과 마찬가지로 이 기법 역시 $(k-1)n$ 크기의 단일 이차계획 문제로 다분류 SVM 문제를 확장시키는 기법이다. 그러나 Crammer and Singer 방법은 앞의 기법보다 최적화 모형의 제약식에 있어서 더 적은 여유 변수(slack variables)를 필요로 한다는 점에서 차이가 있다[Crammer and Singer, 2000]. 본 기법 역시 대한 자세한 수리적 접근 원리는 Crammer and Singer[2000]을 참고할 수 있다. 앞서 살펴본 Weston and Watkins 방법과 마찬가지로, 이 기법 역시 약간의 분해기법을 활용하면 보다 빠르게 최적화된 해를 찾을 수 있다[Hsu and Lin, 2002a; Hsu and Lin, 2002b].

일반적으로 Weston and Watkins 방법이나 Crammer and Singer 방법을 적용할 경우, 분류기를 찾는 과정과 방법이 매우 복잡하기 때문에, 대단히 많은 컴퓨팅 자원을 필요로 한다[Hsu and Lin, 2002a; Lorena and de Carvalho, 2008]. 그 결과, 실제적으로는 이 두 방법에 비해 다분류 문제를 여러 개의 이분류 SVM 문제로 쪼개서 해결하는 방법이 더 빈번하게 적용되고 있는 실정이다[Lorena and de Carvalho, 2008].

2.4 다분류 SVM을 적용한 채권등급평가 모형에 관한 연구

전술했듯이 지금까지 채권등급평가에 주로 적용되어 온 인공지능기법은 인공신경망이었다. 그러나 2004년 이후, 인공신경망에 대한 한계점을 극복하기 위해, 다분류 SVM을 적용한 채권등급평가 연구가 자주 소개되고 있다. 본 절에서는 이와 같은 다분류 SVM을 적용한 채권등급평가 관련 연구들을 살펴보고, 그 한계점을 지적해 보

도록 한다.

우선 2004년에 발표된 Huang *et al.*[2004]의 연구는 최초로 신용등급 예측모형에 다분류 SVM 기법을 적용했다는 점에서 의의가 큰 논문이다. 그들은 MSVM의 다분류 SVM 기법들 중에서, One-Against-One과 Crammer and Singer 방법의 2가지를 적용하여 대만과 미국기업들의 신용등급 예측모형을 구축하였다. 그들은 최적의 다분류 SVM 모형을 구축하기 위해 다양한 파라미터 값들을 적용하였는데, 그 결과 $\sigma^2 = 10$, $C = 1000$ 을 갖는 RBF 커널 함수(kernel function) 기반의 Crammer and Singer 방법이 가장 우수한 성과를 보임을 확인하였다. 또한 이 다분류 SVM 기법이 전통적으로 많이 사용되어온 역전파 알고리즘(BP) 기반의 인공신경망이나 로지스틱 회귀모형보다도 더 높은 예측력을 보임을 확인하였다. 그러나 이들의 연구는 예측결과의 차이가 통계적으로 유의한지에 대해서는 확인하지 아니하였다.

Cao *et al.*[2006]은 One-Against-All, One-Against-One, 그리고 DAGSVM 등 총 3가지 기법을 이용해, S&P에서 제공하는 채권등급을 예측하는 모형을 구축하고자 하였다. 커널 함수로는 가우시안 RBF(Gaussian RBF) 함수를 사용하였으며, σ^2 와 C 의 값은 그리드 탐색 방법(grid-search)을 이용해 최적값을 탐색하였다. 그 결과, 상기 3개의 기법들 중 DAGSVM이 가장 우수한 것으로 판명되었다. 또한 세 기법 모두 로지스틱 회귀모형이나 순서형 프로빗 회귀모형(ordered probit regression), 그리고 역전파 알고리즘 기반의 인공신경망 기법보다 더 우수한 예측성과를 보임을 제시하였다.

Chen and Shih[2006]은 대만의 신용등급 자동 판별모형을 구축하기 위해 One-Against-One 방식의 다분류 SVM 기법을 제안하였다. 앞의 Cao *et al.*[2006]의 연구와 유사하게, 이들도 가우시안 RBF 함수를 커널 함수로 사용하였고, 최적 파라미터 값은 그리드 탐색전략을 통해 탐색

하였다. 그 결과, 다분류 SVM 기법이 인공신경망이나 로지스틱 회귀모형과 비교해 통계적으로 더 우수한 예측 성과를 보임을 제시하였다.

한편 Ahn *et al.*[2006]은 다분류 SVM 모형에 기반한 국내 채권등급 예측모형을 제시하였는데, 이 논문에서는 One-Against-One, Weston and Watkins 방법, 그리고 Crammer and Singer 방법을 이용해 다분류 SVM 모형을 구축하였다. 그 결과, 다분류 SVM 모형이 다중판별분석이나 인공신경망 기법에 비해 통계적으로 더 우수한 예측성능을 제공함을 확인하였다. 하지만, 이 연구는 5-집단 교차 검증(5-fold cross validation)을 수행하면서, 각 집단마다 서로 다른 최적의 다분류 SVM 기법을 적용해 예측성능을 산출하였기 때문에, 3가지 다분류 SVM 기법들 중에서 어느 기법이 가장 우수한 성과를 보이는지에 대해서는 효과적으로 제시하지 못했다는 한계가 있다.

마지막으로 Lee[2007]는 Chen and Shih[2006]와 유사한 연구를 수행했는데, 다만 국내 기업들을 대상으로 한 신용등급평가 모형을 구축하고자 했다는 점에서 차이를 가진다. 그도 앞의 연구들과 마찬가지로 가우시안 RBF 커널함수와 그리드 탐색전략을 적용하였다. 그렇게 해서, 다분류 SVM 기법이 인공신경망이나 다중판별분석, 그리고 사례기반추론과 비교해 더 우수한 예측성능을 제공함을 확인하였다.

이상 살펴본 기존 연구들은 다음과 같은 공통적인 한계점을 지닌다. 우선, 앞 절에서 살펴본 바와 같이 다분류 SVM을 구현하는 기법에는 6가지 대표적인 기법들이 존재함에도 불구하고, 기존 연구들은 1~3개 정도의 기법들만 비교, 분석하고 있다. 또한 다분류 SVM 기법간 성과의 차이에 대해서는 Cao *et al.*[2006]의 연구를 제외하고는 전혀 보고되지 않고 있다. 그리고, 기존 연구들 중 Chen and Shih[2006]와 Ahn *et al.*[2006]의 몇몇 연구를 제외하고는 기존 기법과 다분류 SVM 기법간의 성과 차이가 통계적으

로 유의한지에 대해서 검증과정이 생략되어 있다는 한계가 있다. 또한 SVM 모형의 설계에 있어서도, Ahn *et al.*[2006]의 연구를 제외하고는 모두 가우시안 RBF 함수 하나만을 활용하는 한계를 보이고 있다.

이에 본 연구에서는 앞서 소개한 6가지 기법들과 이들 중 일부의 변형 모형까지 모두 적용해 보고, 이 중에서 채권등급평가에 가장 적합한 기법은 어떤 것인지 알아보고자 한다. 아울러, 통계적으로 성과의 차이가 유의한 지에 대해서도 함께 검증해 볼 것이다. 커널 함수와 관련해서는 선형 함수, 다항 함수, 가우시안 RBF 함수의 3가지 함수를 모두 적용해 볼 것이며, SVM의 성능에 있어서 중요한 영향을 미치는 커널 함수의 상한 C 와 커널 파라미터 σ^2 와 d 에 대해 그리드 탐색 방법을 적용, 최적값을 탐색하고자 한다[Tay and Cao, 2001; Ahn *et al.*, 2006].

III. 데이터와 실험 설계

3.1 실험 데이터

앞서 소개한 연구 목적을 달성하기 위해, 우리는 다분류 SVM의 6가지 기법들을 국내 기업채권등급 예측모형 개발에 적용하였다. 대상이 된 데이터는 제조업에 소속된 KOSPI 혹은 KOSDAQ 상장기업 중 총 1295개의 기업들이다. 예측의 목적변수, 즉 종속변수는 이들 기업들의 회사채 신용등급으로 하였으며, 이들 기업의 신용등급은 2002년에 발표된 한국신용정보의 공시 자료를 이용하였다. 국내에서 기업의 신용등급은 크게 A1, A2, A3, B, C의 5등급으로 구분되는데, 본 연구에서는 편의상 A1은 1, A2는 2, A3는 3, B와 C는 합쳐서 4로 표기하였다. B와 C 등급을 하나의 등급으로 묶은 이유는 C등급에 해당하는 사례의 수가 매우 적어 등급 구분에 어려움이 있고, 일반적으로 신용평가회사들이 신용등급을 부여할 때 대부분의 기업들에 대해 하한을 B등급

으로 부여하는 관행을 갖고 있어서, 'B등급 이하'는 그 자체로 투자부적격채권(junk bond)의 의미를 갖기 때문이다[Ahn *et al.*, 2006].

독립변수로 활용할 변수들을 만들기 위해, 한국상장회사협의회에서 제공하는 데이터베이스에서 추출한 해당 기업들의 재무제표 변수들을 이용해 총 39개의 재무비율변수들을 생성하였다. 상기 39개의 변수는 모두 기존 연구에서 기업의 신용등급을 결정하는데 유의한 것으로 밝혀진 변수들로서, 규모지표 10개, 수익성지표 12개, 안정성지표 10개, 현금흐름지표 4개, 생산성지표 3개로 구성되어 있다[Lee *et al.*, 1996; Shin and Han, 1999; Park *et al.*, 2000; Huang *et al.*, 2004]. 그러나 이 변수들을 모두 모형에 포함시키기에는 그 수가 너무 많았기 때문에, 통계 기법들을 동원하여 유의한 변수만 따로 선정하였다. 이를 위해 우선, 일원배치 분산분석(One-way ANOVA)을 적용해 기업신용등급과 95% 신뢰수준 하에서 유의한 것으로 밝혀진 총 36개의 변

수를 선정하였다. 이어, 순차적 다차원판별분석(stepwise MDA)을 통해, 최종적으로 선택된 총 14개의 변수들만 분석에 활용하였다. 다음의 <표 2>는 본 실험에 적용된 14개의 독립변수에 대한 목록을 나타내고 있다.

모형의 구축을 위한 자료의 구분을 위해, 학습용(training) 데이터로 각 등급의 80%에 해당하는 데이터를 그리고 나머지 20%를 검증용(validation) 데이터로 사용하였다. 아울러, 예측성과의 차이가 통계적으로 유의한지를 살펴보기 위해서는 패턴을 분명하게 관찰할 수 있도록 충분한 사례를 확보하는 것이 요구되는데, 이를 위해 5-집단 교차 검증(5-fold cross validation)기법을 적용하였다.

3.2 실험 데이터

앞의 제 2.4절에서 언급한 바와 같이, 본 연구에서는 총 3종류의 커널함수에 대해 모두 실험

<표 2> 실험에 활용된 최종 입력변수

구 분	코드	변수의 의미
규모지표	SHEQ	자기자본
	SALE	매출액
	DEBT	총부채
	YEAR	업력
생산성지표	SAPE	1인당 매출액
수익성지표	NIPS	주당 순이익
	AETA	유보액대총자산비율
	BDRA	금융비용부담율
	FCTC	금융비용대총비용비율
안정성지표	FIRA	고정자산구성비율
	IACA	재고자산대유동자산비율
	SBTB	단기차입금대총차입금비율
현금흐름 지표	CFTA	현금흐름대총자본비율
	OACF	(영업활동으로 인한 현금흐름-현금배당)/(고정자산 + 운전자본) 비율

을 진행하였으며, 각 커널함수와 관련된 파라미터들(C, d, σ^2)에 대해 최적값을 찾기 위해 그리드 탐색기법을 적용하였다. One-Against-All, One-Against-One, DAGSVM, 그리고 ECOC 기법을 구현하기 위해, 본 연구에서는 복수 개의 이분류 SVM 분류기들을 사전에 정해진 방식에 의해 결합할 수 있는 사후 처리 소프트웨어(post-processing software)를 작성, 활용하였다. 이 프로그램은 Microsoft Visual Basic for Applications for Excel 2003로 개발되었는데, 텍스트 파일로 생성되는 이분류 SVM의 결과를 MS-Excel 프로그램으로 자동으로 불러들여 그 결과를 해석할 수 있도록 설계되었다. 이분류 SVM의 실험은 다른 연구에서도 대부분 사용하고 있는 Chang and Lin[2001]의 LIBSVM ver 2.6을 사용하였다. 아울러, Weston and Watkins 방법과 Crammer and Singer의 방법을 구현하기 위한 소프트웨어로는 Hsu and Lin[2006]이 제공한 BSVM ver 2.06을 사용하였다.

다분류 SVM 기법의 경우, 역사가 짧은 최신의 방법론으로서, 여전히 현업에서는 채권등급평가의 수단으로 MDA나 ANN같은 전통적인 기법들을 더 많이 활용하고 있다. 때문에, 새롭게 제안되는 다분류 SVM기법이 과연 기존 기법과 비교했을 때 더 우수한지, 그리고 우수하다면 얼마나 더 우수한 성과의 차이를 보이는지 살펴보는 것은 그 의미가 크다. 이에, 본 연구에서는 채권등급 예측에 있어서 전통적으로 많이 활용되어 온 통계 또는 인공지능 기법들을 비교모형으로 적용해 보았다. 총 3가지를 적용하였는데, 이들은 (1) 판별분석; (2) 다항 로지스틱 회귀분석; 그리고 (3) 인공신경망 기법이다. 판별분석과 다항 로지스틱 회귀분석과 관련해서는, 시행착오(trial-and-error) 방법을 통해 최적의 모형을 찾고자 하였다. 인공신경망의 경우에는 기본적인 표준 3계층 역전파 네트워크를 활용하였는데, 은닉층의 노드 개수는 7, 14, 21, 28의 4가지 경우를 모두 실험해 보고, 가장 성과가 우수한 망을

최종 선택하였다. 학습횟수의 경우, 너무 적으면 학습이 제대로 이루어지지 않고, 너무 많으면 학습용 데이터에 과도적합되어 검증용 데이터의 예측력이 떨어지는 경우가 많다. 따라서, 본 연구에서는 학습이 최대한 적당히 이루어지도록 실제 학습용으로 활용된 데이터 개수 779건의 약 50배에 해당되는 38,950회가 지나면 학습이 멈추도록 하였다. 또한 은닉층의 노드들은 시그모이드 전이함수(sigmoid transfer function)를 적용하였고, 출력층의 노드들은 선형 전이함수(linear transfer function)를 적용하였다. 아울러, 인공신경망의 학습율(learning rate)은 0.1, 모멘텀(momentum)은 0.1로 고정하였다.

IV. 실험 결과

각 기법의 성과를 비교하기 위해, 본 연구에서는 '예측 정확도(hit ratio)'를 평가 기준으로 사용하였다. 다음의 <표 3>은 6가지 다분류 SVM 기법들과 2가지 변형기법의 예측 성과를 제시하고 있다. 이 표를 통해 우선 복수개의 이분류 SVM 분류기들을 결합하는 4개 기법들의 성과를 살펴보면, 검증용 데이터를 기준으로 약 55.89%~67.29%의 예측정확도를 나타냄을 알 수 있다. 이 중에서, 순서를 고려한 DAGSVM (67.29%)이 가장 우수한 예측성적을 보였고, One-Against-One(67.21%)이 바로 그 뒤를 이었다. 반면, One-Against-All(64.34%)과 ECOC(64.50%)는 상대적으로 낮은 예측성적을 보임을 알 수 있었다.

본 연구에서 제시된 이 같은 다분류 SVM 기법 간 예측력의 순서, 즉 DAGSVM > One-Against-One > One-Against-All의 순서는 기존 연구 중 Cao *et al.*[2006]의 연구결과와 정확하게 일치한다. 이러한 현상이 나타난 근본적인 원인으로, 우리는 '구축된 분류기의 수'가 하나의 원인이 될 수 있음을 지적하고 싶다. k 개의 등급으로 구성된 다분류 문제에서 DAGSVM과 One-Against-One 기법은 kC_2 개의 분류기를 참조해 등급을 판

정하는 반면, One-Against-All 기법은 단지 k 개의 분류기만 참조한다. 때문에 이로 인한 정보의 손실(information loss)이 예측성과의 차이를 가져온 것이 아닌가 사료된다. 그리고, DAGSVM의 경우, 순서를 고려한 DAGSVM이 순서를 무시한 DAGSVM에 비해 약간 더 우수한 예측성과를 보임을 확인할 수 있었다. 이는 우리에게 순서가 있는 다분류 문제의 경우, '순서 정보'를 분류모형에 접목(embedded)시키는 것이 예측성과 향상에 어느 정도 기여할 수도 있다는 점을 우리에게 시사하고 있다.

본 실험결과에서 가장 의외인 부분은 바로 ECOC의 예측성과가 상당히 낮게 나왔다는 점이다. 본 연구에서 ECOC는 DAGSVM이나 One-Against-One(6개)보다도 더 많은 수(7개)의 분류기를 구축, 활용하였음에도 불구하고, 성과는 매우 낮게 나타났다. 따라서 이 현상은 앞서 설명한 정보의 손실(information loss)로는 그 원인을 설명하기 어렵다. 때문에 우리들은 이 현상의 원인이 구축된 분류기들의 특징의 차이에 있는 것이 아닌가 생각한다. 원리 상 DAGSVM이나 One-Against-One은 단일 등급 對 단일 등급의 분류기를 구축하도록 설계되어 있는 반면, ECOC나 One-Against-All의 경우, 등급 그룹 對 등급 그룹의 분류기를 주로 구축하도록 설계되어 있다. 이 때, 후자의 경우, 만약 등급간 순서가 존재하는 상황에서 인접 등급간 미세한 차이를 잘 구분해 내는 것이 예측 성과에 큰 영향을 미치는 상황에서 상당히 불리할 수 있다. 따라서, 본 실험에서 ECOC의 성과가 낮게 나온 주요 원인은 우리가 실험한 채권등급평가 데이터가 앞서 소개한 것처럼 인접 등급간 구분이 매우 중요한 특징을 가진 데이터라, 이런 실험결과가 나온 것이 아닌가 생각된다.

모든 데이터를 한꺼번에 고려해 통합 SVM 모형을 구축하는 기법들의 경우, 검증용 데이터에 대해 Weston and Watkins 방법은 67.05%의 예측 성과를 보인 반면, Crammer and Singer

의 방법은 64.89%의 예측 성과를 보임을 확인할 수 있었다. 하지만 이 두 기법 모두 DAGSVM(67.29%)이나 One-Against-One(67.21%) 기법과 비교했을 때, 예측성과가 상대적으로 더 떨어지는 것으로 나타났다. 따라서, 채권등급평가 영역에서는 다분류 SVM를 구현하는 두 부류의 기법 중, 복수 개의 이분류 SVM 분류기들을 결합하는 접근법이 더 효과적인 것으로 나타났다.

본 연구에서 처음 제안한 ECOC의 변형 기법의 경우, 모든 사례에 대해 예측결과를 산출하지는 않기 때문에 다른 다분류 SVM 기법과 성과를 직접적으로 비교하는 것이 불가능하다. 하지만, 전체 검증용 데이터의 53.57%에 해당하는 예측결과를 산출한 샘플에 대해서는 무려 79.49%의 높은 예측 적중률을 보임을 확인할 수 있었다. 따라서, 이 기법 역시 패턴이 분명한 사례들에 대해 높은 예측 정확도를 요구하는 특별한 상황에서 유익하게 활용될 수 있을 것으로 기대된다.

다음의 <표 4>는 다른 비교 기법들-MDA, MLOGIT 그리고 ANN 기법에 대한 실험결과를 제시하고 있다. 이 표에서 볼 수 있듯이, 인공신경망의 예측성과(65.66%)가 가장 높고, 다중판별분석의 성과(63.10%)가 가장 낮은 것으로 나타났다. 다중판별분석이나 다항 로지스틱 회귀분석의 경우, 기본적으로 선형관계를 가정하는 통계모형에 근간한 기법들이기 때문에, 비선형 패턴을 모형에 반영할 수 있는 인공신경망 모형에 비해 이론상 현실세계를 반영하는데 다소 제약이 있다. 이러한 제약들로 인해 세가지 기법들 중 ANN의 성과가 가장 높게 나온 것이 아닌가 사료된다.

<표 5>에는 앞서 소개한 10개 기법들(6개의 제안기법과 3개의 비교기법)간 성과의 차이가 과연 통계적으로 유의한지를 살펴보는 McNemar의 검정결과가 제시되어 있다. 이 표에 제시된 바와 같이, 가장 우수한 성과를 보인 (순서를 고려한) DAGSVM의 경우, 다중판별분석(MDA)에 대해 99% 신뢰수준 하에서, 다항 로지스틱 회귀

<표 3> 다분류 SVM 실험 결과

Data Set	One Against All		One Against One		순서를 고려한 DAGSVM		순서를 무시한 DAGSVM		ECOC		변형된 ECOC*		Weston과 Watkins의 방법		Crammer와 Singer의 방법	
	학습	검증	학습	검증	학습	검증	학습	검증	학습	검증	학습	검증	학습	검증	학습	검증
1	73.10%	65.50%	75.80%	65.12%	65.19%	64.73%	65.19%	64.73%	73.00%	66.28%	84.76%	76.13%	67.12%	65.89%	81.58%	65.12%
2	76.37%	63.18%	84.09%	65.12%	69.62%	65.12%	69.53%	64.73%	79.85%	61.63%	78.47%	75.19%	75.99%	64.73%	63.74%	62.79%
3	63.36%	64.34%	67.21%	69.38%	67.60%	69.77%	67.41%	69.77%	62.97%	65.12%	76.69%	84.92%	66.44%	69.38%	63.26%	64.73%
4	80.04%	65.12%	76.47%	68.22%	76.18%	68.60%	76.18%	68.60%	73.10%	65.12%	84.56%	77.30%	81.20%	68.99%	86.40%	66.67%
5	64.80%	63.57%	75.31%	68.22%	75.60%	68.22%	75.60%	67.83%	62.01%	64.34%	77.96%	83.90%	67.31%	66.28%	64.51%	65.12%
Avg.	71.53%	64.34%	75.78%	67.21%	70.84%	67.29%	70.78%	67.13%	70.18%	64.50%	80.49%	79.49%	71.61%	67.05%	71.90%	64.89%

주) * 변형된 ECOC 모형의 적용비율은 검증용 데이터에 대해 평균 53.17%를 나타냈으며, Data Set 1~5까지 나누어 살펴보면 각각 60.08%, 50.00%, 43.84%, 63.18%, 그리고 45.14%로 나타났다.

<표 4> 비교 기법 실험 결과

Data Set	MDA		MLOGIT		ANN		
	학습	검증	학습	검증	학습	테스트	검증
1	65.86%	59.30%	67.70%	63.95%	70.22%	64.73%	64.73%
2	64.90%	62.02%	67.98%	63.57%	71.76%	65.50%	65.12%
3	64.51%	69.38%	65.96%	68.99%	69.45%	63.18%	66.67%
4	64.80%	65.50%	67.79%	67.44%	69.19%	64.73%	67.44%
5	65.09%	59.30%	66.15%	63.18%	67.14%	68.60%	64.34%
Avg.	65.03%	63.10%	67.12%	65.43%	69.55%	65.35%	65.66%

분석(MLOGIT)과 One-Against-All (OAA) 그리고 ECOC에 대해 95% 신뢰수준 하에서 통계적으로 유의한 성과의 차이를 보이고 있음을 알 수 있다. 한편 Crammer and Singer 방법(CS)에 대해서는 90% 신뢰수준 하에서 유의한 성과 차이를 보이고 있는 것으로 나타났으며, 인공신경망(ANN)이나 One-Against-One(OAO) 그리고 Weston and Watkins 방법(WW)과는 통계적으로 유의한 성과차이가 나타나고 있지 않음을 확인할 수 있다.

인공신경망 기법의 경우, 다른 통계 기법들과 달리 복잡다단한 현실세계의 비선형 패턴을 모형

에 반영할 수 있다는 근원적 장점을 갖고 있으며, 그 결과 인공신경망은 일반적으로 기존의 통계 모형에 비해 상당히 높은 예측결과를 보이고 있다. 이런 이유로 본 연구에서 다중판별분석이나 다항로지스틱 회귀모형과 달리, 유독 인공신경망만 순서를 고려한 DAGSVM의 예측성과와 별 차이 없는(통계적으로 차이가 없는) 높은 예측 정확도를 나타낼 수 있었던 것이 아닌가 추정된다.

V. 결 언

본 연구에서는 지금까지 컴퓨터 과학 분야에

<표 5> McNemar 검정 결과

	MLOGIT	ANN	OAA	OAO	DAGSVM	ECOC	WW	CS
MDA	4.163**	5.044**	0.611	10.859***	11.903***	0.781	10.917***	1.238
MLOGIT		0.028	0.693	2.766*	4.069**	0.513	3.150*	0.131
ANN			1.020	1.861	2.073	0.800	1.700	0.285
OAA				5.918**	5.801**	0.010	5.279**	0.275
OAO					0.000	5.479**	0.007	3.115*
DAGSVM						5.326**	0.030	3.321*
ECOC							4.433**	0.088
WW								2.641

주) *** 99% 신뢰수준 하에서 통계적으로 유의, ** 95% 신뢰수준 하에서 통계적으로 유의, * 90% 신뢰수준 하에서 통계적으로 유의.

서 제시된 총 6가지의 다분류 SVM 기법들과 2가지 변형기법을 제시하고, 채권등급평가 분야에 있어 이들 기법들이 어떤 효과를 갖는지 확인하기 위해 이들을 실제 국내 채권등급 사례에 적용해 보았다. 아울러, 전통적으로 채권등급 평가에 많이 활용되어 온 4가지 기법들도 함께 같은 데이터에 적용해 보고, 다분류 SVM 기법과 그 성과를 비교해 보았다. 그 결과, 순서를 고려한 DAGSVM 기법이 채권등급평가 분야에 있어 가장 우수한 성과를 보인다는 사실을 확인할 수 있었다. 아울러 본 연구에서 처음으로 제안한 ECOC의 변형기법의 경우, 비록 50% 초반대의 적용비율(coverage)²⁾을 나타내 약 절반 정도의 사례에 대해서만 예측결과를 산출하는 단점은 있으나, 나머지 50%의 패턴이 분명한 사례들에 대해서는 상당히 높은 수준의 예측 정확도를 보임을 알 수 있었다.

본 연구의 의의는 크게 다음의 3가지 정도로 요약해 볼 수 있다. 우선 본 연구는 6가지 다분류 SVM 기법들을 채권등급평가에 모두 적용해 본 최초의 연구로서, 어떤 기법이 채권등급평가에 적합한 지에 대해 일종의 지침(guideline)을 제시했다는 측면에서 첫 번째 의의가 있다. 특히, 최근 다른 공학 분야에서는 상대적으로 높은 예측력으로 인해 6가지 다분류 SVM의 기법들 중 ECOC가 많이 활용되는 추세에 있는데[Klautau et al., 2003; Übeyli, 2008; Wu et al., 2008 등], 본 연구는 채권등급평가의 경우, 인접 등급간 섬세한 분류가 더 중요할 수 있으므로 ECOC의 예측력이 오히려 높지 않을 수 있음을 제시하고 있다. 이는 앞으로 다분류 SVM을 적용하고자 하는 신용평가 회사나 개인 연구자들에게 중요한 교훈을 제공해 줄 수 있을 것이다.

본 연구의 두 번째 의의는 다분류 SVM을 구현하는 새로운 변형 기법들을 제시하였다는 점이다. 우선 본 연구에서는 순서를 고려한 DAGSVM

의 경우, 순서를 무시한 DAGSVM에 비해 채권등급평가 분야에서는 약간 더 우수한 예측성결과를 제공함을 확인하였다. 따라서, 앞으로 DAGSVM을 설계하고자 할 때에는 적용하고자 하는 다분류 문제에 순서가 있는지 혹은 없는지에 따라, DAG의 설계 방식이 차별화되어야 함을 본 논문의 실험결과가 시사하고 있다. 아울러, 특수한 경우에 한정되어 사용되겠지만, 변형된 ECOC 기법 역시 높은 예측 정확도를 요구하거나, 예측결과의 신뢰도를 제공해야 하는 다분류 문제에서 유익하게 활용될 수 있을 것으로 사료된다. 특히 본 연구에서 제안된 ECOC의 변형기법은 다른 이분류 모형에도 얼마든지 적용될 수 있는 방식이다. 이분류 문제에서 분류기준 값의 경계영역에 속한 그레이(grey) 영역을 제외하면, 모형의 성과는 일반적으로 높아지기 때문이다. 이런 맥락에서 비단 SVM의 ECOC 뿐만 아니라, 다른 이분류 기법에도 이와 유사한 아이디어를 접목한 연구가 앞으로 이루어질 수 있을 것으로 기대된다.

본 연구의 마지막 의의는 향후 다분류 SVM 기법과 관련한 연구방향에 새로운 화두를 제시하고 있다는 점이다. <표 3>에 제시된 본 연구의 실험결과에 따르면, 순서정보를 고려한 DAGSVM 모형의 경우, 그렇지 않은 모형에 비해 미약하나마 예측 성과의 개선효과를 나타내고 있다. 따라서, 이러한 ‘순서 정보’를 보다 효과적으로 고려하고, 반영하는 새로운 다분류 SVM 기법을 개발해 보고, 과연 실제로 성과개선에 효과가 있는지를 검증하는 연구가 향후 이루어질 필요가 있다는 점을 본 연구는 시사하고 있다.

본 연구의 한계점과 향후 연구방향은 다음과 같다. 지금까지 살펴 본 바와 같이, 다분류 SVM은 비단 채권등급평가 분야 뿐만 아니라, 다른 경영 분야의 다분류 문제에 있어서도 유익하게 활용될 수 있다. 때문에, 고객관계관리 분야에서 고객등급을 구분하는 문제라거나, 기타 다른 경영분야의 다분류 문제 해결에 6가지 다분류 SVM 기법들을 적용해 보고, 그 효과를 살펴볼 필요가

2) 전체 예측대상 사례 중, 예측결과가 정상적으로 산출된 사례가 차지하는 비율.

있다.

아울러, 연구의 세번째 의의에서 지적인 바와 같이 등급간 순서를 고려한 새로운 형태의 다분류 SVM 기법을 개발, 연구할 필요가 있다. 이와 관련해, 이분류 인공지능망 기법들을 결합하여, 순서가 있는 다분류 문제 해결에 응용하고자 한 Kwon *et al.*[1997]의 OPP(Ordinal Pairwise Partitioning) 방법론을 다분류 SVM에 적용하는 방법도 고려해 볼 수 있다. 이러한 기법을 적절히 활용할 경우, 앞서 DAGSVM과 마찬가지로

로 예측성과를 향상시킬 수 있을 것이다. 또한 비록 이러한 기법이 예측성과에 크게 개선효과를 가져오지 못한다고 하더라도, OPP 방법을 적용하면 기존의 One-Against-One이나 One-Against-All 기법에 비해 더 적은 수의 분류기로 예측을 수행하는 것이 가능하다. 따라서, OPP는 보다 효율적이면서도 효과적인 다분류 모형을 구현할 수 있는 가능성을 제공해 줄 수 있다고 판단되며, 이런 맥락에서 향후 이 분야에 대한 보다 활발한 후속 연구가 이루어져야 할 것으로 생각된다.

〈References〉

- [1] Ahn, H., Kim, K.-j., and Han, I. "Intelligent Credit Rating Model for Korean Companies using Multiclass Support Vector Machines," *Korean Management Review*, Vol. 35, No. 5, 2006, pp. 1479-1496.
- [2] Altman, E.I., Marco, G., and Varetto, F. "Corporate Distress Diagnosis Comparisons Using Linear Discriminant Analysis and Neural Networks," *Journal of Banking and Finance*, Vol. 18, No. 3, 1994, pp. 505-529.
- [3] Cao, L., Guan, L.K., and Jingqing, Z. "Bond rating using support vector machine," *Intelligent Data Analysis*, Vol. 10, No. 3, 2006, pp. 285-296.
- [4] Chang, C.-C. and Lin, C.-J. LIBSVM : a library for support vector machines, 2001. Software available at <http://www.csie.ntu.edu.tw/~cjlin/libsvm/>.
- [5] Chaveesuk, R., Srivaree-Ratana, C., and Smith, A.E. "Alternative neural network approaches to corporate bond rating," *Journal of Engineering Valuation and Cost Analysis*, Vol. 2, No.2, 1999, pp. 117-131.
- [6] Chen, W.-H. and Shih, J.-Y. "A study of Taiwan's issuer credit rating systems using support vector machines," *Expert Systems with Applications*, Vol. 30, No. 3, 2006, pp. 427-435.
- [7] Crammer, K. and Singer, Y. "On the Learnability and Design of Output Codes for Multiclass Problems," *Proceedings of the 13th Annual Conference on Computational Learning Theory*, 2000, pp. 35-46.
- [8] Dietterich, T.G., and Bakiri, G. "Solving multiclass learning problems via error-correcting output codes," *Journal of Artificial Intelligence*, Vol. 2, 1995, pp. 263-286.
- [9] Dutta, S. and Shekhar, S. "Bond rating: a non-conservative application of neural networks," *Proceedings of IEEE International Conference on Neural Networks*, 1988, pp. II443-II450.
- [10] Ederington, H.L. "Classification models and bond ratings," *Financial Review*, Vol. 20, No. 4, 1985, pp. 237-262.
- [11] Fisher, L. "Determinants of risk premiums on corporate bonds," *Journal of*

- Political Economy*, Vol. 67, 1959, pp. 217-237.
- [12] Friedman, J. "Another Approach to Polychotomous Classification," *Technical Report*, Stanford Univ., 1996.
- [13] Hsu, C-W. and Lin, C.-J. "A Comparison of Methods for Multiclass Support Vector Machines," *IEEE Transactions on Neural Networks*, Vol. 13, No. 2, 2002a, pp. 415-425.
- [14] Hsu, C-W. and Lin, C.-J. "A Simple Decomposition Method for Support Vector Machines," *Machine Learning*, Vol. 46, 2002b, pp. 291-314.
- [15] Hsu, C-W. and Lin, C.-J. BSVM: a SVM library for the solution of large classification and regression problems, 2006. Software available at <http://www.csie.ntu.edu.tw/~cjlin/bsvm/>.
- [16] Huang, Z., Chen, H., Hsu, C.-J., Chen, W-H. and Wu, S. "Credit Rating Analysis with Support Vector Machines and Neural Networks: A Market Comparative Study," *Decision Support Systems*, Vol. 27, 2004, pp. 543-558.
- [17] Jo, H., and Han, I. "Integration of case-based forecasting, neural network, and discriminant analysis for bankruptcy prediction," *Expert Systems with Applications*, Vol. 11, 1996, pp. 415-422.
- [18] Kim, J.W. "Expert systems for bond rating: a comparative analysis of statistical, rule-based and neural network systems," *Expert Systems*, Vol. 10, 1993, pp. 167-171.
- [19] Kim, K. "Financial time series forecasting using support vector machines," *Neurocomputing*, Vol. 55, No. 1-2, 2003, pp. 307-319.
- [20] Klautau, A., Jevtic, N., and Orlitsky, A. "On nearest-neighbor error-correcting output codes with application to all-pairs multiclass support vector machines," *Journal of Machine Learning Research*, Vol. 4, No. 1, 2003, pp. 1-15.
- [21] Kreßel, U. "Pairwise Classification and Support Vector Machines," In Schölkopf, B., Burges, C. and Smola, A.J.: *Advances in Kernel Methods: Support Vector Learning*, Chapter 15. MIT Press. Cambridge, MA, 1999, pp. 255-268.
- [22] Kwon, Y.S., Han, I.G., and Lee, K.C. "Ordinal Pairwise Partitioning (OPP) approach to neural networks training in bond rating," *Intelligent Systems in Accounting, Finance and Management*, Vol. 6, 1996, pp. 23-40.
- [23] Lee, K.C., Han, I., and Kim, M.J. "Study on the Credit Evaluation Model Integrating Statistical Model and Artificial Intelligence Model," *Journal of the Korean Operations Research and Management Science Society*, Vol. 21, No. 1, 1996, pp. 81-100.
- [24] Lee, Y.-C. "Application of support vector machines to corporate credit rating prediction," *Expert Systems with Applications*, Vol. 33, No. 1, 2007, pp. 67-74.
- [25] Lorena, A.C., and de Carvalho, A.C.P.L.F. "Investigation of Strategies for the Generation of Multiclass Support Vector Machines," In Nguyen, N.T., and Katarzyniak, R.: *New Challenges in Applied Intelligence Techniques*, Springer-Verlag. Berlin, Germany, 2008, pp. 319-328.
- [26] Park, K.-N., Lee, H.-Y., and Park, S.-K. "A Hybrid Credit Rating System using

- Rough Set Theory," *Journal of the Korean Operations Research and Management Science Society*, Vol. 25, No. 3, 2000, pp. 125-135.
- [27] Pinches, G.E., and Mingo, K.A. "A multivariate analysis of industrial bond ratings," *Journal of Finance*, Vol. 28, No. 1, 1973, pp. 1-18.
- [28] Pinches, G.E., and Mingo, K.A. "The role of subordination and industrial bond ratings," *Journal of Finance*, Vol. 30, No. 1, 1975, pp. 201-206.
- [29] Platt, J.C., Cristianini, N. and Shawe-Taylor, J. "Large Margin DAG's for multiclass classification," In Solla, S.A., Leen, T.K. and Muller, K.-R.: *Advances in Neural Information Processing Systems*, Vol. 12. MIT Press. Cambridge, MA, 2000, pp. 547-553.
- [30] Shin, K.S., and Han, I. "Case-based reasoning supported by genetic algorithms for corporate bond rating," *Expert Systems with Applications*, Vol. 16, No. 2, 1999, pp. 85-95.
- [31] Shin, K.S., and Han, I. "A case-based approach using inductive indexing for corporate bond rating," *Decision Support Systems*, Vol. 32, 2001, pp. 41-52.
- [32] Statnikov, A., Aliferis, C.F., Tsamardinos, I., Hardin, D. and Levy, S. "A Comprehensive Evaluation of Multicategory Classification Methods for Microarray Gene Expression Cancer Diagnosis," *Bioinformatics*, Vol. 21, No. 5, 2005, pp. 631-543.
- [33] Tay, F.E.H. and Cao, L.J. "Application of Support Vector Machines in Financial Time Series Forecasting," *Omega*, Vol. 29, 2001, pp. 309-317.
- [34] Übeyli, E.D. "Multiclass support vector machines for diagnosis of erythematosquamous disease," *Expert Systems with Applications*, Vol. 35, No. 4, 2008, pp. 1733-1740.
- [35] Vapnik, V. *The Nature of Statistical Learning Theory*. New York, NY: Springer-Verlag, 1995.
- [36] Weston, J. and Watkins, C. "Support Vector Machines for Multiclass Pattern Recognition," *Proceedings of the Seventh European Symposium on Artificial Neural Networks*, 1999, pp. 219-224.
- [37] Wu, Y.-C., Lee, Y.-S., and Yang, J.-C. "Robust and efficient multiclass SVM models for phrase pattern recognition," *Pattern Recognition*, Vol. 41, No. 9, 2008, pp. 2874-2889.

◆ About the Authors ◆



Hyunchul Ahn

Hyunchul Ahn is a full-time lecturer at the School of Business IT, Kookmin university. He received his Ph.D. from KAIST Graduate School of Management. His research interests include business applications of artificial intelligence, behavioral models explaining adoption of information systems, and collective intelligence. His papers have been published in *Annals of Operations Research*, *Applied Soft Computing*, *Expert Systems*, *Expert Systems with Applications*, *Information and Management*, and so on.



Kyoung-jae Kim

Kyoung-jae Kim is an associate professor of Department of MIS, Dongguk University. He received his Ph.D. from KAIST. He has published in *Annals of Operations Research*, *Applied Intelligence*, *Applied Soft Computing*, *Computers in Human Behavior*, *Expert Systems*, *Expert Systems with Applications*, *Intelligent Data Analysis*, *Intelligent Systems in Accounting, Finance and Management*, *Neural Computing and Applications*, *Neurocomputing*, and other journals. His research interests include data mining, knowledge management and intelligent agents.